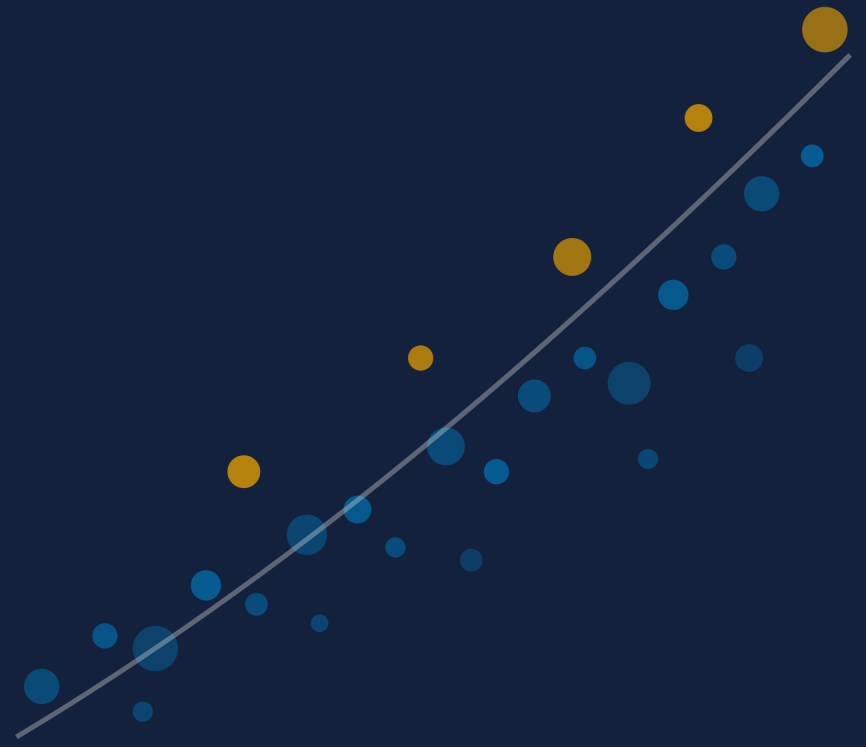
OFICINA RSTUDIO · SNCT 2026 · IFSP BARRETOS

Dos números às conclusões

Dia 2 · Resumir, testar e relatar



Guaraci Requena · UFV, Campus Florestal

Ciência Delas — Mulheres Fazendo História

ONDE PARAMOS

Ontem vimos, hoje vamos ver

ONTEM

RStudio, script e pacotes

Vetores, funções e NA

Importar o devs.csv

Quatro gráficos com ggplot2

HOJE

Resumir com números

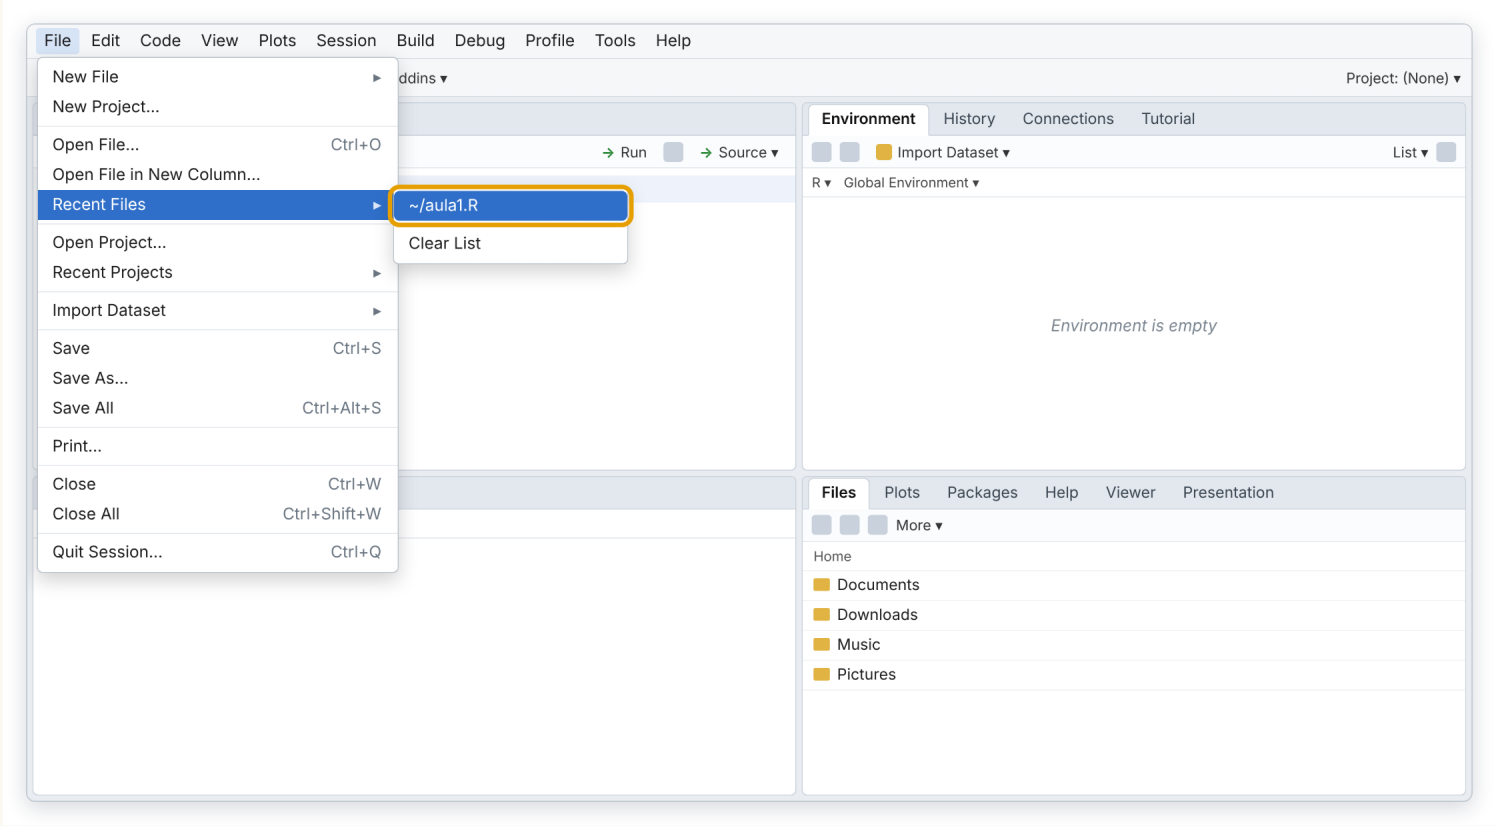
Testar: diferença real ou acaso?

Medir relação: correlação e regressão

Relatório em Word com um clique

PASSO 1

Abra o RStudio e o script de ontem



File › Recent Files › aula1.R

Não aparece? Crie um script novo (Ctrl + Shift + N) e siga o próximo slide.

Hoje vamos salvar como **aula2.R** (File › Save As...).

PASSO 2

Três linhas preparam tudo

```
library(dplyr)
library(ggplot2)
devs ← read.csv("C:/Users/aluno/Downloads/devs.csv")
```

Rode as três (selecione e aperte Ctrl + Enter). Confira no Environment: **devs, 739 obs. of 7 variables**.

`there is no package called…`

O computador apagou os pacotes: **Tools › Install Packages**, dplyr, ggplot2

`cannot open file…`

Importe de novo pelo menu: **Import Dataset › From Text (base)**

PARTE 1

Resumir com números

Um número bem escolhido conta muito. Um mal escolhido engana.

RESUMIR

Quanto ganha um dev “típico”?

Você escreve	O R responde
`mean(devs$salario)`	`[1] 14279.29`
`median(devs$salario)`	`[1] 10021`

Média

Soma tudo e divide pelo número de pessoas.

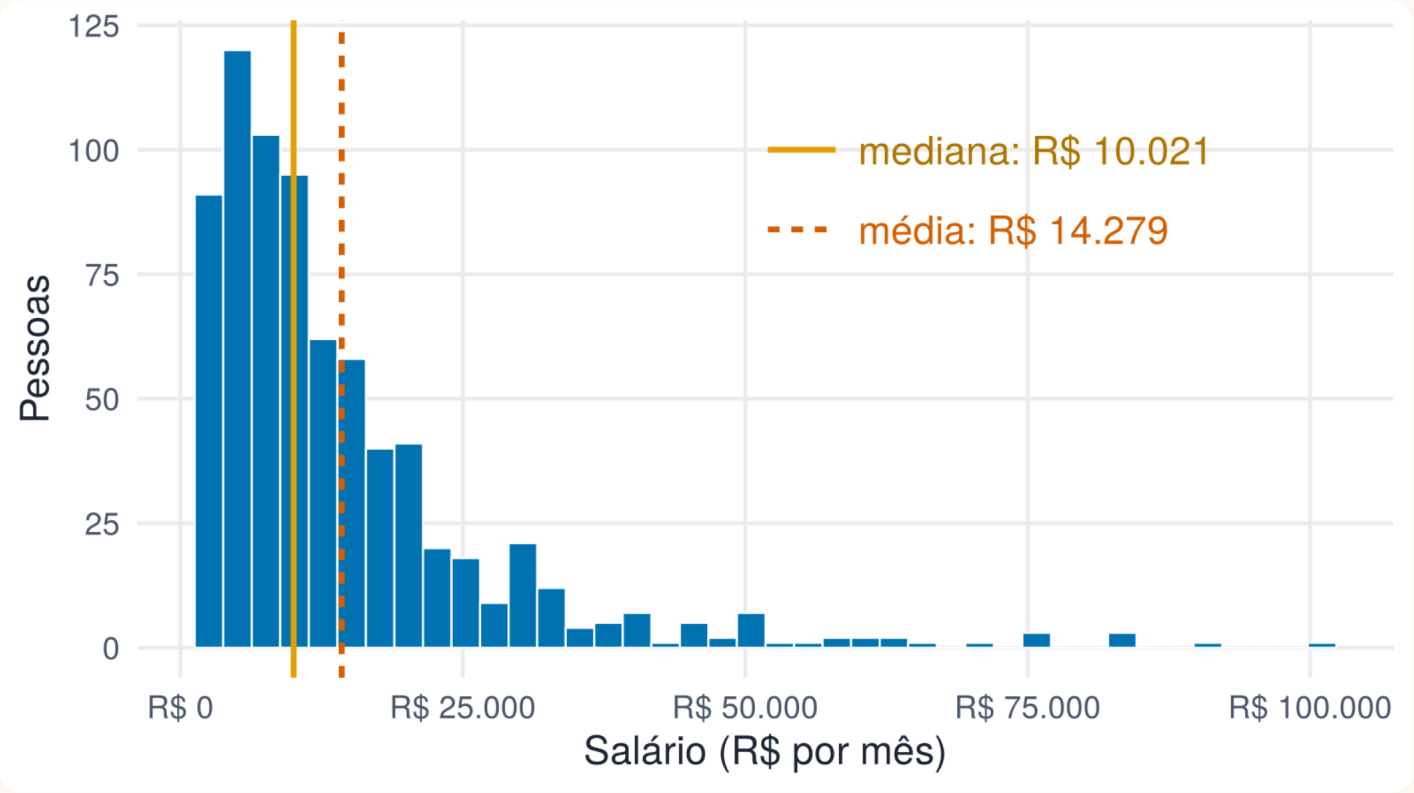
Mediana

O valor do meio: metade ganha menos, metade ganha mais.

Mais de R$ 4 mil de diferença. Qual das duas descreve melhor?

RESUMIR

Poucos salários altos puxam a média



A maioria está à esquerda. A cauda longa à direita puxa a média para cima.

Para o dev “típico”, a **mediana** descreve melhor.

Mesma lógica de “renda média” de um país.

RESUMIR

summary(): seis números de uma vez

```
summary(devs$salario)
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   1472    5833   10021   14279   17688  100000
```

1st Qu. = 5.833
25% ganham até R$ 5.833

Median = 10.021
metade ganha até R$ 10.021

3rd Qu. = 17.688
25% ganham mais de R$ 17.688

Quanto os valores variam? **sd(devs$salario)** dá o desvio-padrão: 13442.95

RESUMIR CATEGORIAS

Contagens e porcentagens

Você escreve

```
tabela ← table(devs$modelo_trabalho)
tabela
```

O R responde

```
   Híbrido Presencial     Remoto
       186         109        444
```

```
round(100 * prop.table(tabela), 1)
```

```
   Híbrido Presencial     Remoto
      25.2        14.7       60.1
```

prop.table transforma contagens em proporções; **100 *** vira porcentagem; **round(..., 1)** arredonda.

60% dos respondentes trabalham remoto.

RESUMIR POR GRUPO

A mediana de cada modelo de trabalho

```
tapply(devs$salario, devs$modelo_trabalho, median)
```

```
   Híbrido Presencial     Remoto
    9833.5     5417.0    12050.0
```

Lê-se: “aplique a **mediana** ao **salário**, separado por **modelo de trabalho**”.

A mediana do remoto é mais que o dobro da do presencial.

RESUMIR POR GRUPO · DPLYR

O mesmo resumo, escrito como uma frase

```
devs |>
  group_by(modelo_trabalho) |>
  summarise(
    pessoas = n(),
    media   = mean(salario),
    mediana = median(salario)
  )
```

O **|>** se lê “e então” (atalho: Ctrl + Shift + M).

“Pegue devs, e então agrupe por modelo, e então resuma.”

n() conta as pessoas de cada grupo.

```
  modelo_trabalho pessoas  media mediana
1 Híbrido             186 13023.   9834.
2 Presencial          109  7382.   5417
3 Remoto              444 16499.  12050
```

RESUMIR POR GRUPO · DPLYR

Filtrar, contar e ordenar

Você escreve

```
devs |>
  filter(modelo_trabalho == "Remoto") |>
  summarise(mediana = median(salario))
```

O R responde

```
  mediana
1   12050
```

```
devs |>
  count(cargo, sort = TRUE)
```

```
       cargo   n
1 Full-stack 327
2   Back-end 171
3     Outros  53  …
```

filter escolhe linhas · **count** conta · **arrange(desc(x))** ordena do maior para o menor

Para comparar, use **==** (dois iguais). Um = sozinho dá erro.

EXERCÍCIO · 8 minutos

Sua vez de resumir

1

Mediana do salário de quem usa IA (**usa_ia == "Sim"**)

2

Quantas pessoas em cada **escolaridade**, da maior para a menor

3 · desafio

Mediana do salário por **cargo**, da maior para a menor

Dica: copie os exemplos dos slides anteriores e troque só o que muda.

A PERGUNTA DA SEGUNDA PARTE

Remoto ganha mais de verdade, ou foi sorte da amostra?

Mediana remoto: **R$ 12.050** Mediana presencial: **R$ 5.417**

PARTE 2

Diferença real ou acaso?

Testes de hipótese, correlação e regressão.

CIÊNCIA DELAS · A ORIGEM DOS TESTES

A cientista que provava chá

Inglaterra, anos 1920. A bióloga **Muriel Bristol** diz que sabe, pelo gosto, se o leite foi posto antes ou depois do chá.

O estatístico Ronald Fisher propõe um teste: **8 xícaras**, 4 de cada jeito, em ordem sorteada.

Ela acertou todas.

A PERGUNTA DE FISHER

E se ela estivesse só chutando?

A CONTA DE FISHER

Qual a chance de acertar tudo no chute?

Você escreve	O R responde
`choose(8, 4)`	`[1] 70`
`1 / choose(8, 4)`	`[1] 0.01428571`

Há **70** jeitos de escolher 4 xícaras entre 8. Só um é o certo. No chute, a chance de acertar tudo é 1 em 70: **1,4%**.

Esse é o p-valor: se fosse só chute, a chance de acertar tanto assim.

TESTES DE HIPÓTESE

A lógica de todo teste, em três passos

1

Suponha que **não há diferença**: tudo é acaso

(a hipótese nula)

→

2

Calcule a chance de ver dados assim nesse caso

(o p-valor)

→

3

p pequeno (menor que 0,05): o acaso explica mal

(evidência de diferença)

Cuidado: o p-valor não diz o **tamanho** da diferença, nem a **causa**. E 0,05 é uma convenção, não uma lei.

TESTE T · COMPARAR DUAS MÉDIAS

Remoto × presencial: duas linhas de código

```
# 1. fica só com remoto e presencial
duas ← filter(devs, modelo_trabalho ≠ "Híbrido")

# 2. compara o salário médio dos dois grupos
t.test(salario ~ modelo_trabalho, data = duas)
```

!= quer dizer “diferente de”

salario ~ modelo_trabalho: “salário em função do modelo”

TESTE T · LENDO A RESPOSTA

O que o R respondeu

```
  Welch Two Sample t-test

data:  salario by modelo_trabalho
t = -9.046, df = 342.13, p-value < 2.2e-16
alternative hypothesis: true difference in
means between group Presencial and group
Remoto is not equal to 0
95 percent confidence interval:
 -11099.48  -7134.70
sample estimates:
mean in group Presencial    mean in group Remoto
                7381.844            16498.935
```

As médias

Presencial R$ 7.382 · Remoto R$ 16.499

O p-valor

< 2.2e-16: praticamente zero. O acaso não explica.

O intervalo de 95%

O presencial ganha, em média, entre R$ 7.135 e R$ 11.099 a menos.

Conclusão: nestes dados, a diferença é real, e é grande.

PENSAMENTO CRÍTICO

Diferença real não quer dizer “por causa de”

Outras explicações

Quem trabalha remoto pode ter mais experiência, outro cargo, ou trabalhar para empresas de fora.

Quem respondeu

Responde quem quer. O resultado vale para estes 739, não para todos os devs.

O que ficou de fora

59 brasileiros que ganham em dólar, quase todos remotos, não estão na base.

O teste mostra que a diferença existe nestes dados. Ele não diz o que a causa.

QUI-QUADRADO · DUAS CATEGORIAS

Quem trabalha remoto usa mais IA?

Você escreve

```
tab ← table(devs$modelo_trabalho,
            devs$usa_ia)
tab
```

```
chisq.test(tab)
```

O R responde

```
           Não pretende Pretende  Sim
  Híbrido            40       22  124
  Presencial         16       20   73
  Remoto             74       67  301
```

```
  Pearson's Chi-squared test
data:  tab
X-squared = 4.4432, df = 4, p-value = 0.3493
```

p = 0,35: grande. O acaso explica bem. Não há evidência de relação.

QUI-QUADRADO · VENDO O RESULTADO

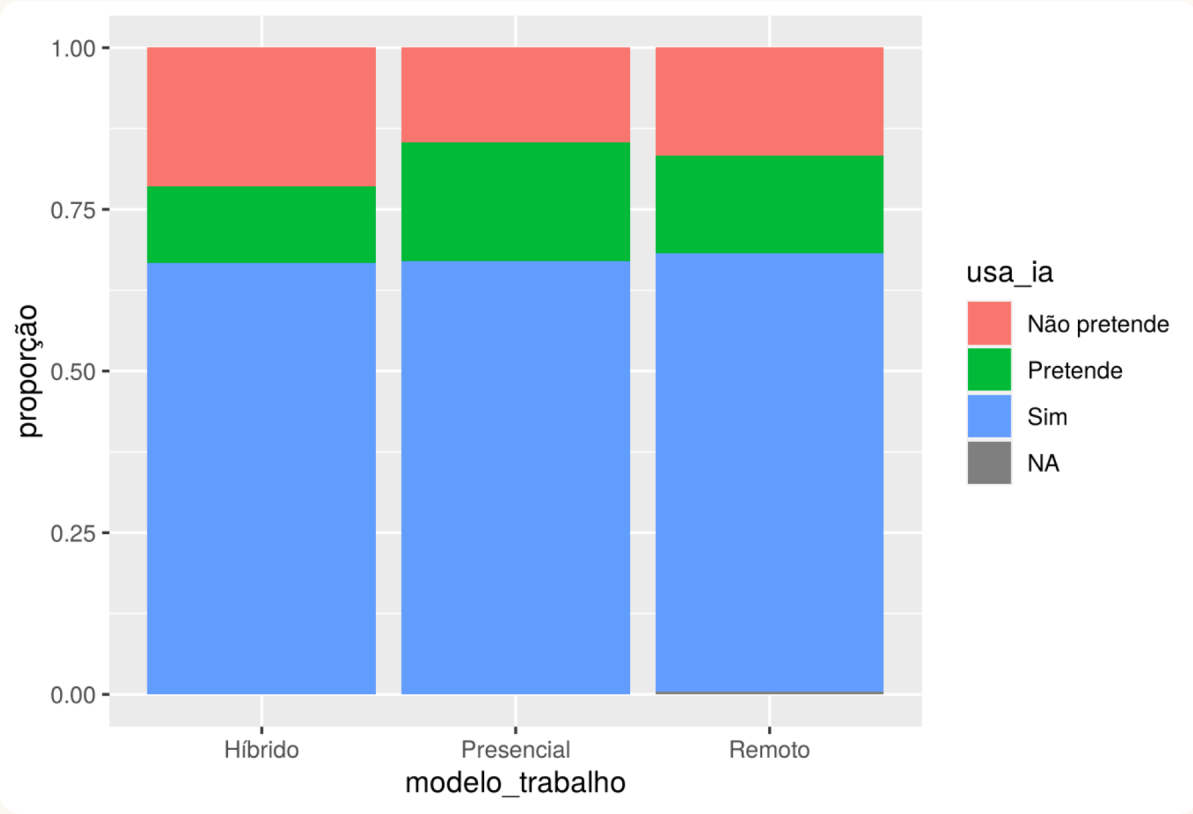
Os três grupos usam IA quase igual

```
ggplot(devs, aes(x = modelo_trabalho,
                 fill = usa_ia)) +
  geom_bar(position = "fill")
```

Em cada grupo, cerca de **67%** usam IA.

position = "fill" mostra proporções: todas as barras vão até 1.

p grande não prova que não há diferença: só que estes dados não mostram uma.



CORRELAÇÃO · DUAS VARIÁVEIS NUMÉRICAS

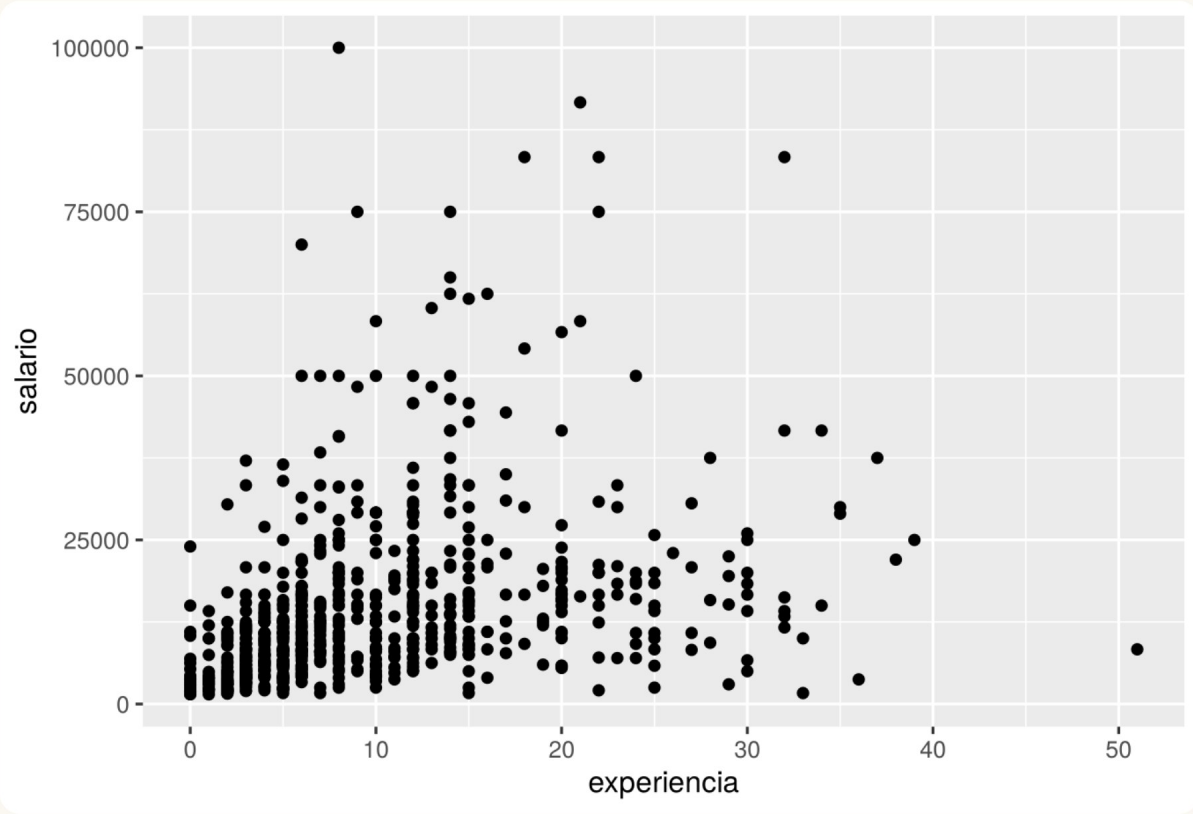
Experiência e salário andam juntos?

```
cor(devs$experiencia,
    devs$salario)
```

```
[1] 0.359015
```

Vai de **−1** a **+1**. Perto de 0: sem relação linear.

0,36: relação positiva, moderada. Sobe junto, mas com muita variação.



REGRESSÃO LINEAR SIMPLES

Quanto vale um ano de experiência?

Você escreve

```
modelo ← lm(salario ~ experiencia,
            data = devs)
modelo
```

O R responde

```
Coefficients:
(Intercept)  experiencia
     8407.5         608.5
```

608,5

Cada ano a mais de experiência: cerca de **R$ 609 a mais por mês**, em média.

8.407,5

O salário que a reta prevê para quem tem **zero** anos de experiência.

A reta: **salário ≈ 8.407 + 609 × anos de experiência**

REGRESSÃO · NO GRÁFICO

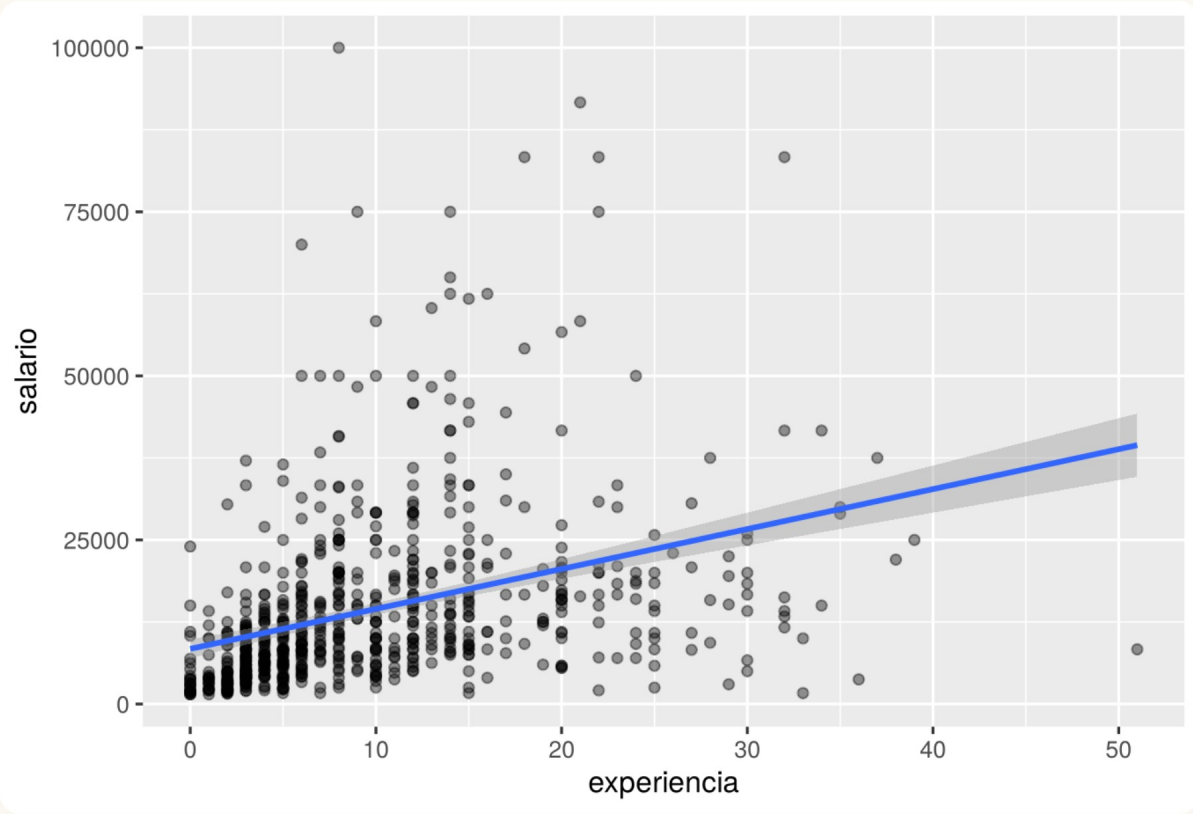
A reta no meio da nuvem

```
ggplot(devs, aes(x = experiencia,
                 y = salario)) +
  geom_point(alpha = 0.4) +
  geom_smooth(method = "lm")
```

geom_smooth(method = "lm") desenha a reta da regressão.

A faixa cinza mostra a incerteza sobre a reta.

alpha = 0.4 deixa os pontos transparentes, para ver onde se acumulam.



REGRESSÃO · QUANTO A RETA EXPLICA

summary(modelo): o relatório completo

```
Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)  8407.52     727.65   11.55   <2e-16 ***
experiencia   608.50      58.27   10.44   <2e-16 ***
...
Multiple R-squared:  0.1289,  Adjusted R-squared:  0.1277
```

p < 2e−16

A experiência tem relação com o salário: não é acaso.

R² = 0,13

A experiência explica só 13% da variação dos salários. Os outros 87% dependem de outras coisas.

EXERCÍCIO · 8 minutos

Teste você mesmo

1

Teste t: **híbrido × presencial**. A diferença é real?

Dica: tire o "Remoto" no filter

2

Para 10 anos de experiência, qual salário a reta prevê?

8407.5 + 608.5 * 10

3 · desafio

Os mais jovens usam mais IA? Qui-quadrado de **faixa_etaria × usa_ia**

PARTE 3

Um relatório em Word, com um clique

Texto, código e resultados no mesmo arquivo.

R MARKDOWN

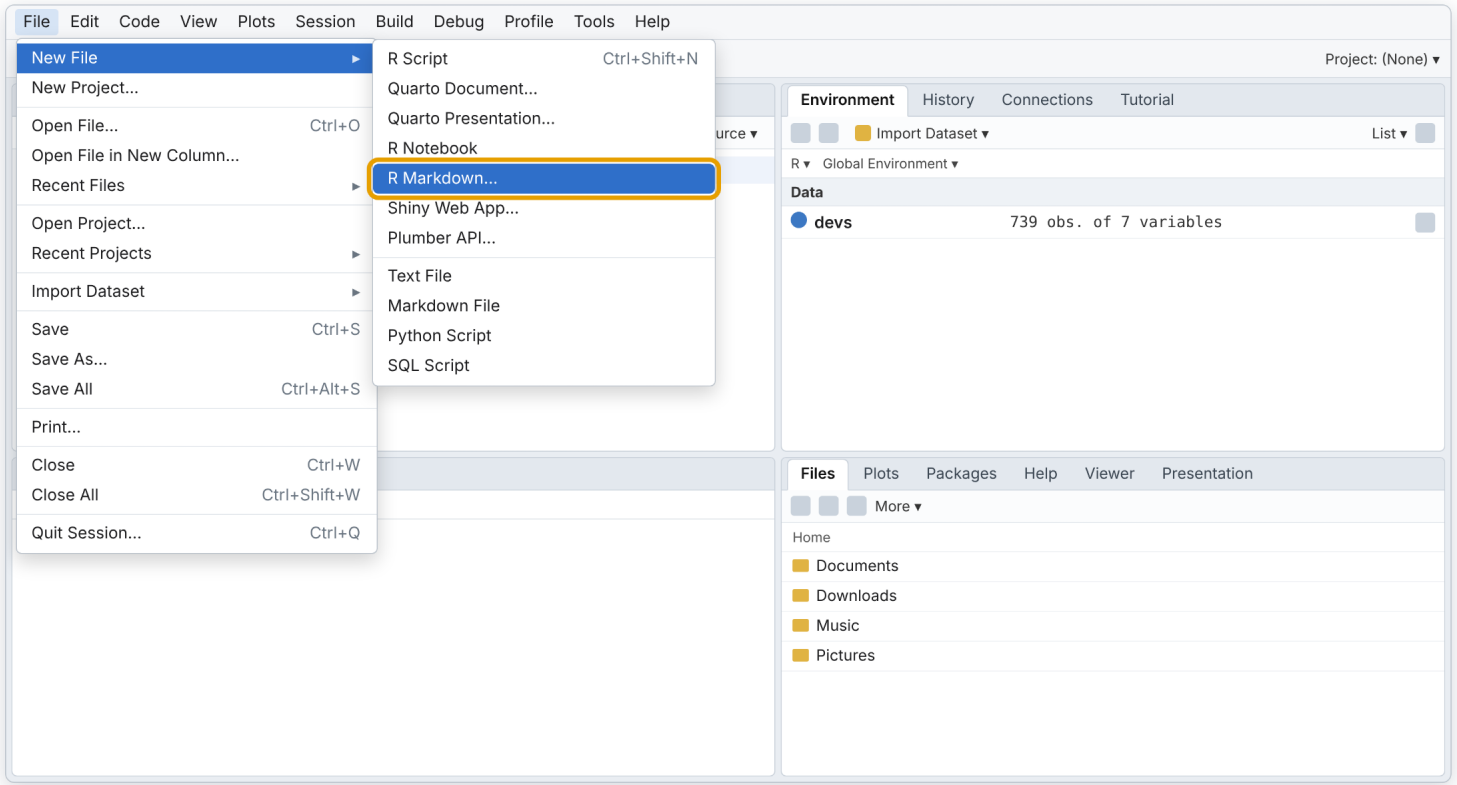
Escreva uma vez, gere o documento sempre que quiser



Mudou o dado? Clique em Knit de novo: o relatório se refaz sozinho. Nada de copiar e colar gráfico.

RELATÓRIO · PASSO 1

Crie um arquivo R Markdown

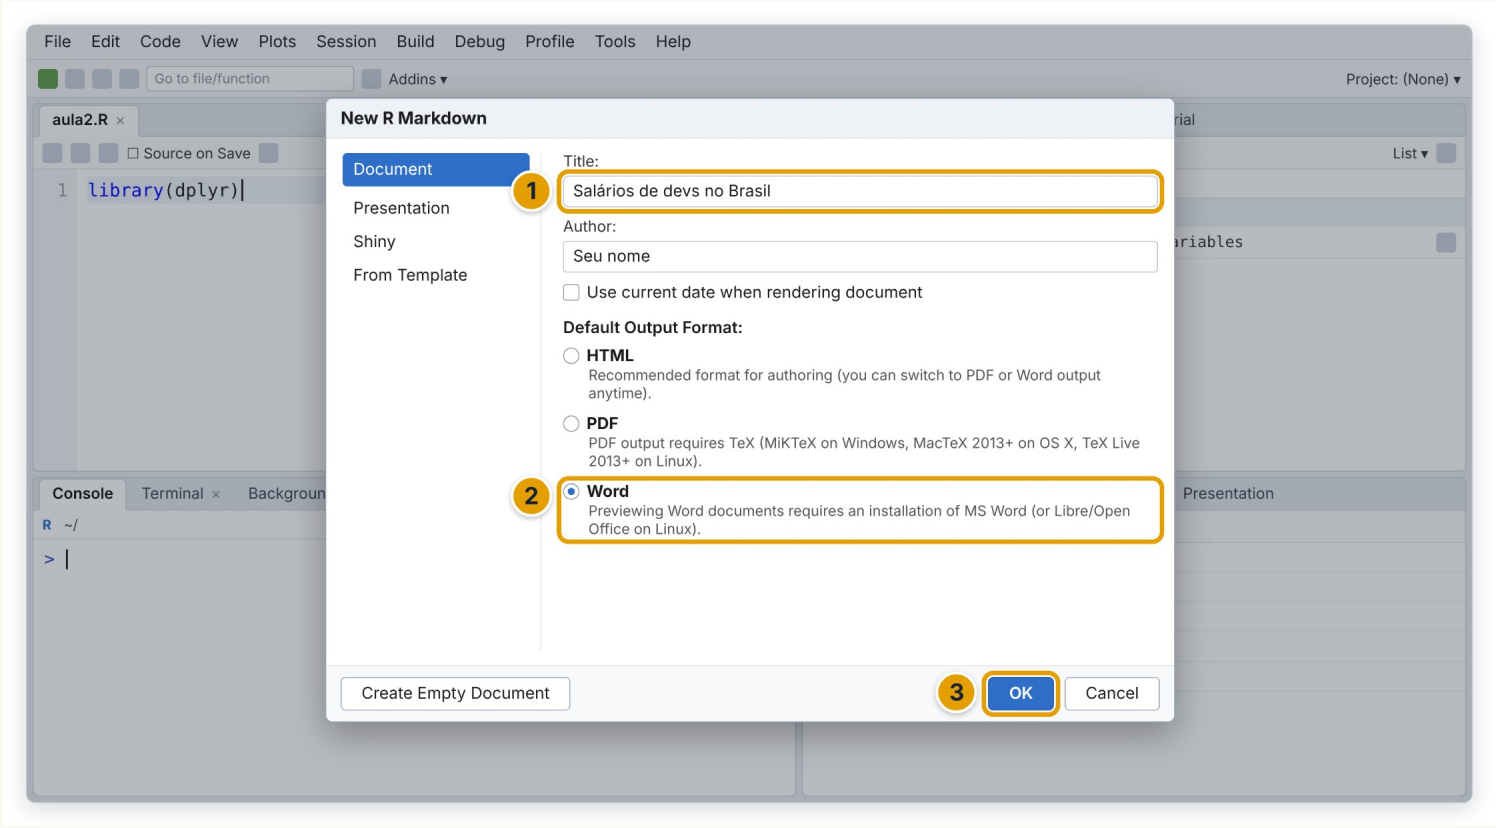


File › New File › R Markdown...

Se aparecer uma janela pedindo para instalar pacotes, clique **Yes** e espere.

RELATÓRIO · PASSO 2

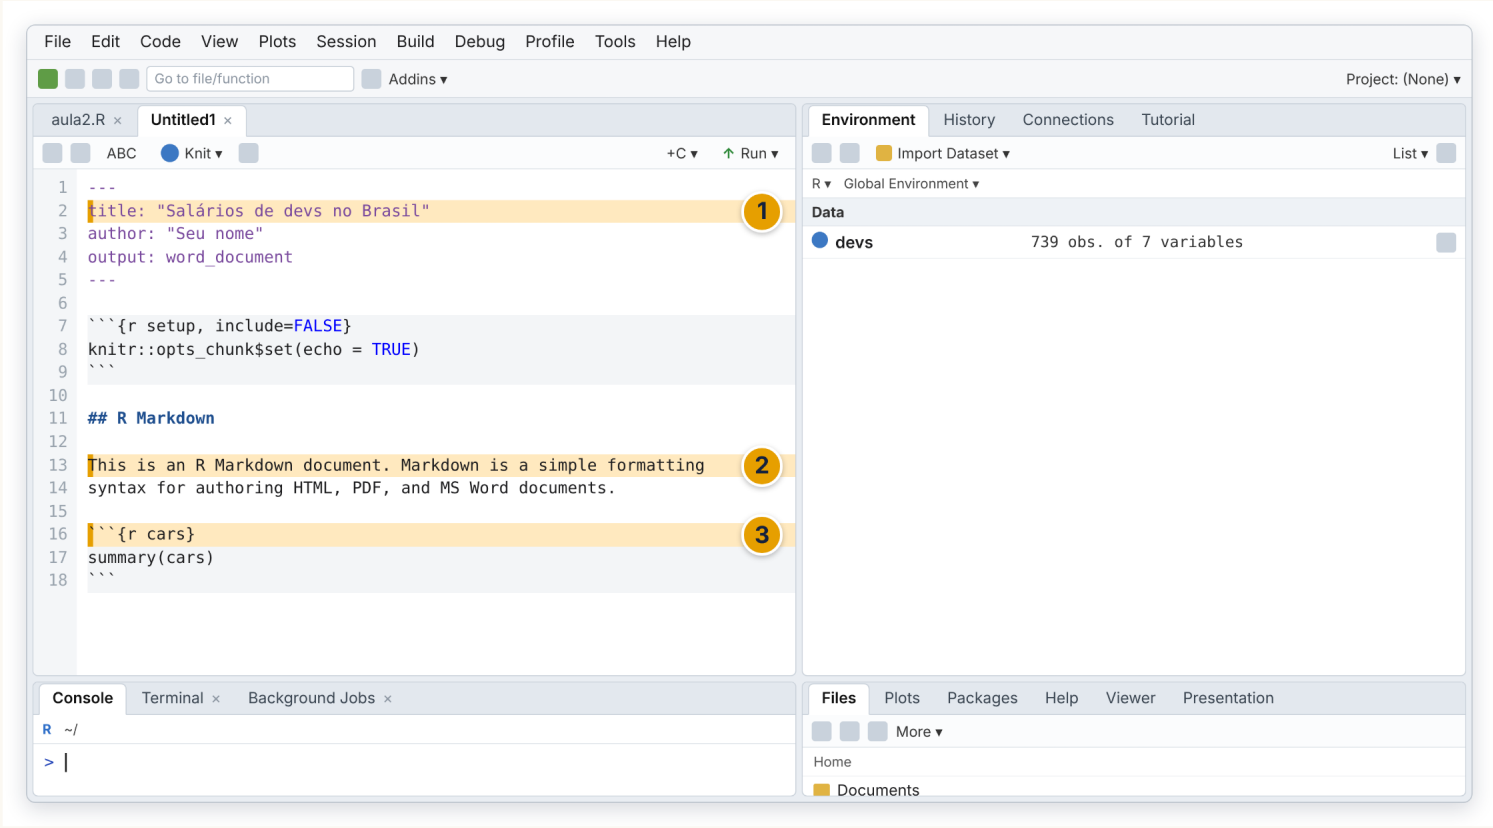
Título, autor e formato Word



1. Escreva o título e o seu nome
2. Escolha **Word**
3. Clique em **OK**

RELATÓRIO · PASSO 3

O modelo que aparece tem três partes



1. **Cabeçalho** entre ---: título, autor, formato
2. **Texto** normal; ## faz um título
3. **Bloco de código**, entre ```{r} e ```

RELATÓRIO · PASSO 4

Salve e escreva o seu relatório

1. **Ctrl + S**: salve como **relatorio** na **mesma pasta do devs.csv** (Downloads)
2. Apague tudo abaixo do cabeçalho (da linha 6 em diante)
3. Escreva o texto ao lado

Por que a mesma pasta? O relatório procura o devs.csv na pasta onde ele está salvo.

````
## Os dados

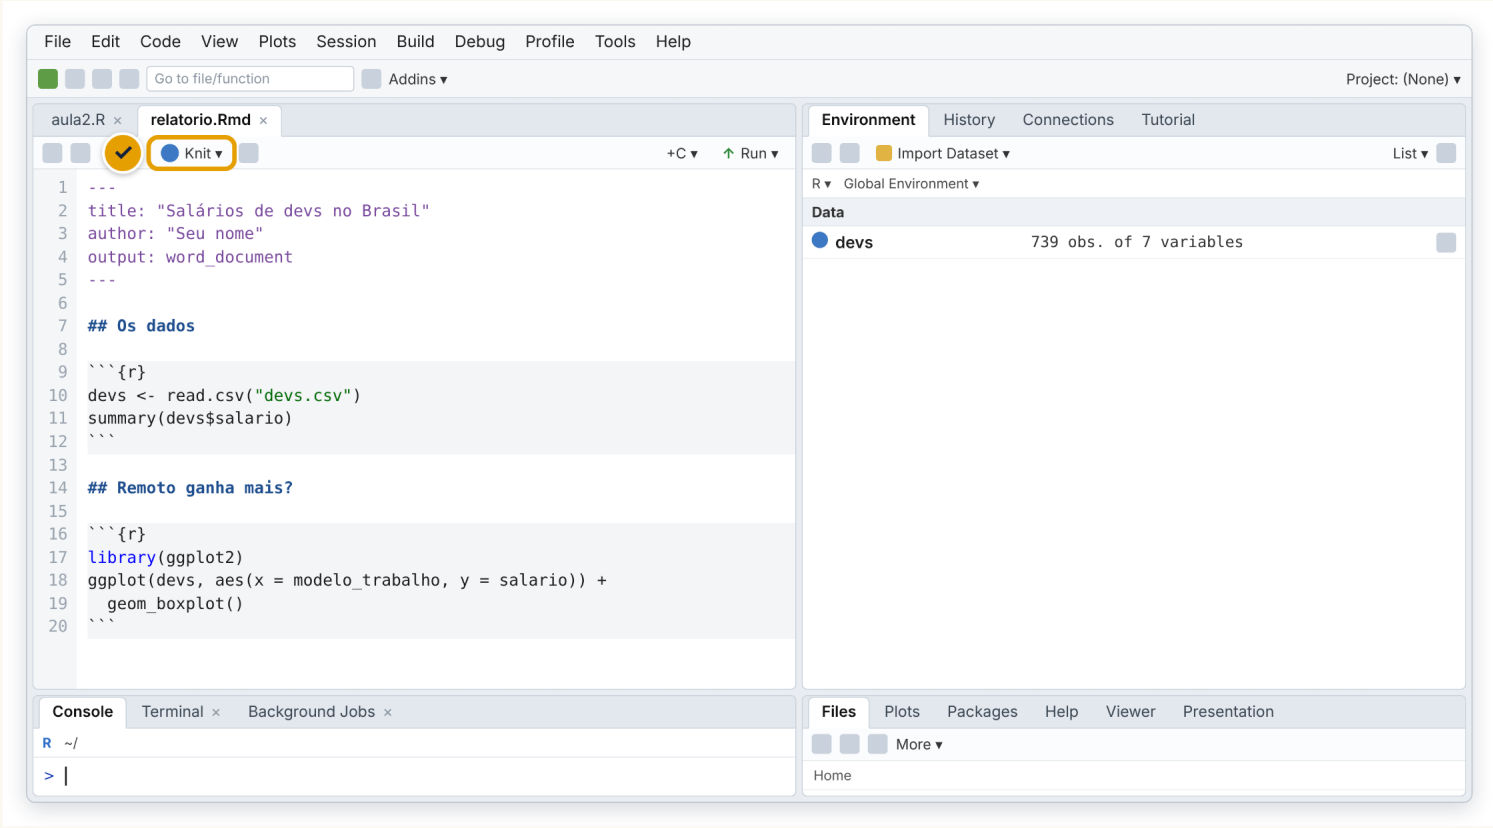
```{r}
devs ← read.csv("devs.csv")
summary(devs$salario)
```


## Remoto ganha mais?

```{r}
library(ggplot2)
ggplot(devs, aes(x = modelo_trabalho, y = salario)) +
  geom_boxplot()
```
````

RELATÓRIO · PASSO 5

Clique em Knit



- Clique em **Knit** (ou Ctrl + Shift + K)

O R roda todos os blocos do zero e monta o documento.

O arquivo **relatorio.docx** aparece na mesma pasta e abre sozinho.

RELATÓRIO · RESULTADO

Seu primeiro relatório reprodutível

Salários de devs no Brasil

Seu nome

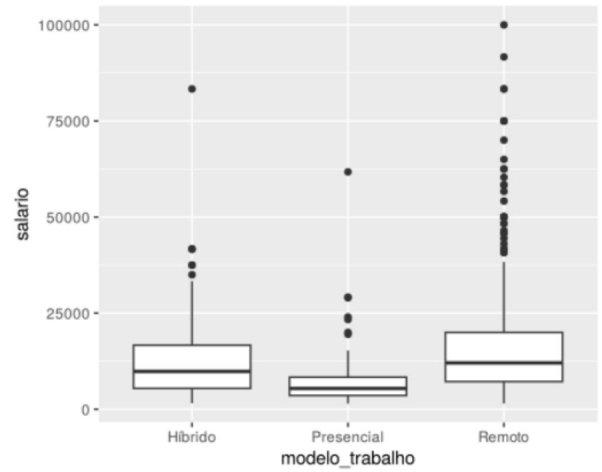
Os dados

```r
devs <- read.csv("devs.csv")
summary(devs$salario)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    1472    5833   10021   14279   17688  100000
```

Remoto ganha mais?

```r
library(ggplot2)
ggplot(devs, aes(x = modelo_trabalho, y = salario)) +
  geom_boxplot()
```



Título, texto, código, resultado e gráfico, tudo gerado pelo R.

Quer em PDF?

No Word: **Arquivo › Salvar como › PDF**.

Esconder o código?

Troque ```` **{r}** por ```` **{r, echo = FALSE}**: só o resultado aparece.

DEU ERRO? CALMA

Erros comuns de hoje e o que fazer

Ciência Delas: em 1947, a equipe de Grace Hopper achou uma mariposa no Mark II e anotou: “primeiro caso real de bug”.

`could not find function "filter"`	Faltou rodar library(dplyr)
`filter(x = "Remoto")` dá erro	Para comparar, use == (dois iguais)
`grouping factor must have exactly 2 levels`	O teste t pede 2 grupos: confira o filter (Híbrido tem acento)
`Chi-squared approximation may be incorrect`	É aviso: há grupos pequenos demais, cuidado com o resultado
`Knit: cannot open file 'devs.csv'`	Salve o .Rmd na mesma pasta do devs.csv
`Knit: object 'devs' not found`	O relatório começa do zero: o read.csv precisa estar dentro dele

PONTOS DE ATENÇÃO

Word aberto com o relatório? Feche antes do Knit · texto entre aspas, com a mesma grafia dos dados · Warning não é erro

FECHAMENTO

Em duas noites, vocês...

- usaram o RStudio e importaram dados
- resumiram dados por grupo
- mediram correlação e regressão
- fizeram gráficos com ggplot2
- rodaram teste t e qui-quadrado
- geraram um relatório em Word

E aprenderam a desconfiar: média engana, e diferença real não é causa.

SEM R NO COMPUTADOR?

posit.cloud: o RStudio no navegador

1. Acesse **posit.cloud** e crie uma conta gratuita (Google ou e-mail)
2. Clique em **New Project › New RStudio Project**
3. Envie o devs.csv em **Files › Upload** e siga os mesmos passos destes slides
4. Em computador compartilhado, **saia da sua conta** ao terminar

DEPOIS DO MINICURSO

Para continuar em casa

Instalar

Primeiro o R (cran.r-project.org), depois o RStudio (posit.co)

Sem instalar

posit.cloud, com conta gratuita

Estudar

Livro gratuito em português: *R para Ciência de Dados* (2ª edição)

Desafio para casa: refaça o relatório com outra pergunta sobre os dados.

SNCT 2026 · CIÊNCIA DELAS

Obrigado!

Florence, Ada, Muriel, Grace, Gabriela: a ciência de dados também tem nome de mulher.

Guaraci Requena · UFV, Campus Florestal